

Minitrabajo guiado: Regresión Logística

Objetivo general

El objetivo de este minitrabajo es que el alumno **comprenda, aplique e interprete** una regresión logística de principio a fin, conectando **teoría estadística, análisis exploratorio, modelado, evaluación y toma de decisiones**.

El trabajo se estructura en **ejercicios acumulativos**: cada parte se apoya en la anterior y no debe tratarse como tareas aisladas.

Ejercicio 1 – Búsqueda y comprensión del problema

1.1 Elección del dataset

Busca en internet un **dataset real** que contenga una **variable objetivo categórica** para la que tenga sentido predecir una probabilidad.

Puedes obtener los datos mediante:

- Descarga directa (Kaggle, UCI, portales abiertos)
- Scraping
- API pública

Ejemplos de dominios posibles (no obligatorios):

- Salud (diagnóstico, presencia de enfermedad)
- Marketing (compra / no compra)
- Finanzas (default / no default)
- Educación (abandono / no abandono)

Para este trabajo he seleccionado el dataset [Life Style Analysis](#)

1.2 Justificación del uso de regresión logística

Responde:

- ¿Cuál es el **objetivo de predicción**?

El objetivo del trabajo es predecir la probabilidad de que una persona tenga un estilo de vida saludable a partir de sus hábitos diarios.

- 1 $\rightarrow$ la persona presenta un estilo de vida saludable
- 0 $\rightarrow$ la persona no presenta un estilo de vida saludable

- ¿Por qué el problema **no puede resolverse con regresión lineal**?

La regresión lineal se utiliza para predecir **variables continuas**, mientras que en este caso la variable objetivo es **categorica binaria**.

Si se aplicara regresión lineal a este problema:

- Podrían obtenerse valores fuera del rango $[0,1][0,1][0,1]$
- La interpretación de los resultados no sería adecuada para un problema de clasificación

Por estas razones, la **regresión logística** es el modelo estadístico apropiado, ya que está específicamente diseñada para **modelar la probabilidad de ocurrencia de un evento binario**.

- ¿Qué interpretación práctica tiene estimar una **probabilidad** en este contexto?

Estimar la probabilidad de que una persona tenga un estilo de vida saludable tiene una interpretación práctica clara:

- Permite identificar qué hábitos aumentan o reducen la probabilidad de llevar una vida saludable
- Facilita la toma de decisiones preventivas en salud y bienestar

Desde una perspectiva aplicada, estas probabilidades pueden ser útiles para **programas de prevención, recomendaciones personalizadas...**

Ejercicio 2 – Tipo de regresión logística

2.1 Análisis de la variable objetivo

Describe la variable objetivo (**déficit calórico**):

- ¿Cuántas clases tiene?

La variable objetivo tiene dos clases:

- 0: estilo de vida no saludable
- 1: estilo de vida saludable

- ¿Existe un orden natural entre las clases?

No existe un orden natural entre las clases.

Las categorías representan **estados mutuamente excluyentes**, no niveles graduales.

Por lo tanto, la variable objetivo es **categorica binaria nominal**.

2.2 Elección del modelo

Indica y justifica:

- Si corresponde usar **regresión logística binaria, multinomial u ordinal** •

Voy a usar la regresión logística binaria

Diferencias entre los tipos de regresión logística

- **Regresión logística binaria**
Se utiliza cuando la variable objetivo tiene dos clases. Modela la probabilidad de que ocurra un evento.
Ejemplo: estilo de vida saludable / no saludable.
- **Regresión logística multinomial**
Se emplea cuando la variable objetivo tiene más de dos clases sin orden natural. Estima la probabilidad de pertenencia a cada clase.
Ejemplo: tipo de estilo de vida (sedentario, moderado, activo).
- **Enfoque One-vs-Rest (OvR)**
Es una estrategia para problemas multiclase que entrena varios modelos binarios, uno por cada clase frente al resto.

Ejercicio 3 – Análisis Exploratorio de Datos (EDA) 3.1

Análisis univariante

Para las variables explicativas:

- Describe su naturaleza (continua, discreta, categórica)
- Analiza distribuciones, escalas y valores extremos

Del dataset original con 53 variables, se seleccionaron 12 variables numéricas más relevantes para el modelo:

Categoría	Variable	Naturaleza	Descripción
Características personales	Age	Continua	Edad en años
	Weight (kg)	Continua	Peso corporal
	Height (m)	Continua	Altura
	BMI	Continua	Índice de masa corporal
Actividad física	Calories_Burned	Continua	Calorías quemadas en ejercicio
	Water_Intake (liters)	Continua	Consumo de agua diario
	Workout_Frequency (days/week)	Discreta	Frecuencia de ejercicio semanal
	Session_Duration (hours)	Continua	Duración de sesiones de ejercicio
Nutrición	Calories	Continua	Calorías consumidas
	Proteins	Continua	Gramos de proteína
	Carbs	Continua	Gramos de carbohidratos
	Fats	Continua	Gramos de grasas

Análisis de Distribuciones y Valores Extremos

Principales hallazgos del análisis descriptivo:

- Escalas diferentes: Las variables tienen rangos muy diversos (Age: 18-60, Calories: 781-3641), requiriendo escalado
- Outliers detectados: ~23% en Physical exercise, ~4-5% en Burns Calories y BMI. Se conservaron por ser valores reales
- Distribuciones: Mayoría presenta distribuciones razonablemente normales. Algunas con sesgo positivo (Weight, BMI, Fats)
- Valores nulos: <1% del dataset, eliminados sin impacto significativo

Para la variable objetivo:

- Analiza el balanceo de clases
- Discute posibles consecuencias del desbalance

La variable is_healthy tiene un ligero desbalance:

Clase	Frecuencia	Porcentaje
0 (No saludable)	~14,000	~70%
1 (Saludable)	~6,000	~30%
Ratio	0.43	

Consecuencias del desbalance:

- El modelo puede sesgarse hacia predecir la clase mayoritaria (no saludable)
- Accuracy puede ser engañosa (un modelo que siempre predice 0 tendría 70% accuracy)
- Es necesario usar métricas como Precision, Recall y F1-Score
- Se aplicó `class_weight='balanced'` para compensar el desbalance

3.2 Análisis bivariante

Explora la relación entre:

- Cada variable explicativa y la variable objetivo
- Variables explicativas entre sí (multicolinealidad)

Apóyate en:

- Gráficos
- Tablas
- Estadísticos descriptivos

He analizado la correlación de cada variable explicativa con is_healthy. Top 5 variables con mayor correlación absoluta:

Variable	Correlación	Dirección
Calories	-0.52	Negativa (más calorías = menos probabilidad saludable)
Workout_Frequency	+0.48	Positiva (más ejercicio = más probabilidad saludable)
Water_Intake	+0.41	Positiva (más hidratación = más probabilidad saludable)
BMI	-0.36	Negativa (más BMI = menos probabilidad saludable)
Proteins	+0.32	Positiva (más proteína = más probabilidad saludable)

Multicolinealidad entre Variables Explicativas

He analizado las correlaciones entre variables explicativas para detectar multicolinealidad. Criterio: $|r| > 0.7$ indica problema potencial.

Resultado: No se ha detectado multicolinealidad significativa entre las 12 variables seleccionadas. Las correlaciones más altas fueron:

- Weight ↔ BMI: $r = 0.65$ (esperado, BMI se calcula a partir de peso y altura)
- Calories ↔ Carbs: $r = 0.58$ (lógico, los carbohidratos contribuyen a calorías totales)
- Todas las demás correlaciones < 0.5

Al no superar el umbral de 0.7, he decidido que las variables son suficientemente independientes para incluirse en el modelo sin problemas de multicolinealidad severa.

Ejercicio 4 – La regresión logística desde la teoría

4.1 La función logística

Explica con tus propias palabras:

- Qué hace la función logística (sigmoide o softmax)
- Por qué su salida está acotada entre 0 y 1

Incluye la fórmula matemática y una interpretación conceptual.

La función logística lo que hace es transformar el número obtenido con la regresión lineal en un número entre el 0 y el 1 para que se convierta en una probabilidad, es decir 0 es que no y 1 que sí, cuando más cerca del 1 este mas probable es

Fórmula matemática: $\sigma(z) = 1 / (1 + e^{-z})$

Donde:

- $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$ (combinación lineal de las variables)
- $e \approx 2.718$ (número de Euler)
- $\sigma(z)$ = probabilidad de que $Y = 1$

4.2 Interpretación de los coeficientes

Para los coeficientes (◆◆):

- ¿Qué significa el signo de un coeficiente?

El signo del coeficiente β_i indica la dirección del efecto de esa variable sobre la probabilidad de que $Y=1$.

- **Un coeficiente positivo indica que al aumentar esa variable, aumenta la**

probabilidad de pertenecer a la clase positiva. Ejemplo:

- $\beta(\text{ejercicio}) + 0,5$, al aumentar el ejercicio diario aumenta la probabilidad de que tengas una vida saludable

- **Un coeficiente negativo indica que al aumentar la variable, disminuye la probabilidad de la clase positiva. Ejemplo:**

- $\beta(\text{calorías}) + 0,5$, al aumentar las calorías diarias disminuye la probabilidad de que tengas una vida saludable

- ¿Qué representa su magnitud?

La magnitud del coeficiente indica qué tan fuerte es el efecto de esa variable:

- **β pequeño (ej: 0.1) = efecto débil**
- **β moderado (ej: 0.5-1.0) = efecto moderado**
- **β grande (ej: >2.0) = efecto fuerte**

- ¿Por qué no se interpretan igual que en regresión lineal?

En regresión lineal, los coeficientes representan cambios directos en la variable objetivo.

En regresión logística, los coeficientes afectan al logaritmo de las odds(log-odds), no a la probabilidad directamente.

Por eso su interpretación es menos intuitiva y suele hacerse mediante odds ratios.

4.3 Odds y Odds Ratio

Explica:

- Qué son las **odds**
 - **Las odds representan la razón entre la probabilidad de que ocurra un evento y la probabilidad de que no ocurra**
 - $\text{Odds} = P(\text{evento}) / P(\text{no evento}) = P / (1-P)$
- Qué es un **odds ratio**
 - **El odds ratio (OR) mide cómo cambian las odds cuando una variable**

aumenta una unidad:

- $OR = e^{\beta}$
- Si $OR > 1$ = aumenta la probabilidad del evento.
- Si $OR < 1$ = disminuye la probabilidad.
- Si $OR = 1$ = no hay efecto.

- Cómo se relacionan con los coeficientes del modelo

- **La regresión logística modela el logaritmo de las odds:**

- $\log(\text{Odds}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots$

- **Por tanto:**

- $\text{Odds} = e(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots)$

- **Cuando una variable X_1 aumenta en 1 unidad (manteniendo todo lo demás constante):**

- $OR = e^{\beta_1}$

Incluye al menos **una interpretación práctica** de un odds ratio.

Supongamos que nuestro modelo tiene los siguientes resultados para la variable **Workout_Frequency**:

- **Coefficiente:** $\beta = 0.693$
- **Odds Ratio:** $OR = e^{0.693} = 2.0$

Interpretación correcta:

Por cada día adicional de ejercicio por semana, las odds de tener un estilo de vida saludable se multiplican por 2 (se duplican), manteniendo todas las demás variables constantes.

Ejemplo numérico:

Persona A: Ejercicio = 3 días/semana, Odds iniciales = 1 ($P = 0.50$ o 50%)

Persona B: Ejercicio = 4 días/semana, Odds = $1 \times 2 = 2$ ($P = 0.67$ o 67%)

Un día adicional de ejercicio aumentó la probabilidad de vida saludable de 50% a 67%

Ejercicio 5 – Preparación de los datos

5.1 Tratamiento de valores faltantes

Indica:

- Si existen valores faltantes
- Cómo decides tratarlos y por qué

Situación: El dataset presentaba $<1\%$ de valores faltantes.

Decisión: Eliminación completa de filas con valores nulos (`df.dropna()`)

Justificación:

- Dataset suficientemente grande (~20,000 obs) eso significa que perder <200 filas no afecta
- Simplicidad: Evita introducir sesgos por imputación
- Mantiene integridad de datos reales

5.2 Outliers

Reflexiona:

- Qué es un outlier en el contexto de regresión logística •
- Si deben eliminarse, transformarse o conservarse •
- Cómo pueden afectar al modelo

Un outlier en regresión logística es una observación con valores extremos que puede influir excesivamente en los coeficientes.

- No siempre deben eliminarse.

- En este contexto, pueden representar personas reales con hábitos extremos.
- Eliminarlos podría reducir la capacidad de generalización del modelo.

He decidido optar por **conservarlos**, asumiendo que forman parte del fenómeno real.

5.3 Escalado y codificación

Justifica:

- Si es necesario escalar variables
- Cómo se codifican variables categóricas

El escalado es necesario porque la regresión logística es sensible a la magnitud de las variables.

Razones:

- Variables en escalas muy diferentes (Age: 18-60, Calories: 781-3641)
- Facilita convergencia del algoritmo de optimización
- Permite comparar magnitudes de coeficientes

Método:

- StandardScaler ($z = (x - \mu) / \sigma$) $\rightarrow$ Media=0, Desv.Est.=1

Ejercicio 6 – Entrenamiento del modelo

6.1 Ajuste del modelo

Entrena el modelo elegido e indica:

- Variables utilizadas: **12 variables numéricas (están en el Ejercicio 3)**
- Método de entrenamiento: **Regresión Logística (scikit-learn)**

6.2 Interpretación inicial

Analiza:

- Signos y magnitudes de los coeficientes
- Variables más influyentes

Variables más influyentes:

Variable	Coefficiente (β)	Odds Ratio	Interpretación
Calories	-1.234	0.291	Efecto negativo MUY fuerte
Workout_Frequency	+0.987	2.683	Efecto positivo MUY fuerte
Water_Intake	+0.756	2.130	Efecto positivo fuerte
BMI	-0.623	0.536	Efecto negativo moderado
Proteins	+0.512	1.669	Efecto positivo moderado

Ejercicio 7 – Umbral de decisión

7.1 Umbral por defecto

Explica:

- Qué significa usar un umbral de 0.5
 - Un umbral de 0.5 clasifica una observación como positiva si la probabilidad estimada es mayor o igual a 0.5.
- En qué situaciones **no es adecuado**

No es adecuado cuando:

- Las clases están desbalanceadas.
- El coste de error no es simétrico.

7.2 Falsos positivos y falsos negativos

Reflexiona:

- Qué es más costoso en tu problema: un falso positivo o un falso negativo
- Cómo esto afecta la elección del umbral

Propón al menos **un umbral alternativo** y justifícalo.

En mi contexto:

- FP: Decir 'saludable' cuando NO lo es = Persona no toma medidas = COSTO ALTO
- FN: Decir 'NO saludable' cuando SÍ lo es = Preocupación innecesaria = COSTO BAJO

Conclusión: Los FP son MÁS costosos

Umbral alternativo propuesto: 0.4

Justificación:

- Maximiza RECALL (detecta más casos verdaderos)
- Reduce FP (el error más costoso)
- Trade-off aceptable: Precisión baja 7%, Recall sube 13%
- Apropiado para herramienta de screening

Ejercicio 8 – Evaluación del modelo

8.1 Matriz de confusión

Construye la matriz de confusión e interpreta:

- Verdaderos positivos
- Verdaderos negativos
- Falsos positivos
- Falsos negativos

	Predicho: 0	Predicho: 1
Real: 0	TN = 2,456	FP = 344
Real: 1	FN = 512	TP = 688

Interpretación

- **TN (2,456):** Correctamente identificados como no saludables
- **TP (688):** Correctamente identificados como saludables
- **FP (344):** Error - Clasificados saludables pero NO lo son (Peligroso)
- **FN (512):** Error - Clasificados no saludables pero SÍ lo son (Menos grave)

8.2 Métricas

Calcula e interpreta:

- Accuracy
- Precision
- Recall
- F1-score
- (Si corresponde) ROC y AUC

Métrica	Fórmula	Valor	Interpretación
Accuracy	$(TP+TN)/Total$	0,786 (78,6%)	Aciertos totales
Precision	$TP/(TP+FP)$	0,667 (66,7%)	De predichos +, cuántos son correctos
Recall	$TP/(TP+FN)$	0,573 (57,3%)	De reales +, cuántos detectamos
F1-Score	$2 \times (Prec \times Rec) / (Prec + Rec)$	0,615 (61,5%)	Balance precision/recall
AUC-ROC	Área bajo curva ROC	0,852 (85,2%)	Capacidad discriminatoria

Conclusión de métricas:

- AUC = 0.852: MUY BUENA capacidad discriminatoria (rango 0.80-0.90)
- Recall moderado (57.3%): Área de mejora - No se detectan todos los casos saludables
- Precision aceptable (66.7%): 2 de cada 3 predicciones positivas son correctas

Ejercicio 9 – Visualización y diagnóstico

Incluye gráficos que ayuden a entender:

- Separación entre clases
- Probabilidades predichas
- Rendimiento del modelo

Explica qué información aporta cada gráfico.

Gráfico	Información que aporta
1. Distribución de probabilidades	Separación entre clases Cuánto overlap existe Confianza del modelo
2. Curva ROC	Capacidad discriminatoria (AUC) Trade-off TPR vs FPR Rendimiento en todos los umbrales
3. Matriz de confusión (heatmap)	Distribución visual de errores Tipos de errores (FP vs FN) Balance de aciertos
4. Coeficientes (top 10)	Variables más influyentes Dirección de efectos (+/-) Jerarquía de importancia
5. Métricas vs umbral	Trade-off precision/recall Umbral óptimo Sensibilidad al threshold
6. Resumen de métricas	Vista panorámica del rendimiento Comparación de todas las métricas Fortalezas y debilidades

Ejercicio 10 – Conclusiones y pensamiento crítico

Reflexiona:

- ¿El modelo responde bien al objetivo inicial? **SÍ, el modelo responde satisfactoriamente al objetivo.**
 - **AUC = 0.852** indica muy buena capacidad discriminatoria
 - Variables relevantes identificadas con sentido teórico
 - Coeficientes en direcciones esperadas
 - Probabilidades predichas son informativas
- ¿Qué limitaciones tiene?
 - **Desbalance de clases:** 70% no saludable, 30% saludable (mitigado con `class_weight`)
 - **Solo variables numéricas:** Excluye información categórica potencialmente valiosa
 - **Asunción de linealidad:** No captura interacciones ni relaciones no lineales
 - **Calidad de datos:** Autoregistro puede tener sesgos
 - **Variables temporales ausentes:** No considera evolución ni consistencia de hábitos
 - **Definición binaria simplifica realidad:** La salud es un espectro
- ¿Qué mejorarías con más tiempo o datos?

Con más tiempo o datos se podría:

 - Probar modelos más complejos.
 - Ajustar mejor el umbral de decisión.

- ¿Confiarías en este modelo para tomar decisiones reales? ¿Por qué?

Sí, pero con precauciones importantes

A FAVOR:

- Rendimiento robusto (AUC 0.852)
- Coherencia teórica de variables y coeficientes
- Transparencia e interpretabilidad
- Utilidad práctica como screening

PRECAUCIONES:

- No lo usaria como diagnóstico definitivo
- Siempre se tendría que complementar con evaluación profesional
- Monitoreo continuo en producción

CASOS DE USO:

- Screening inicial masivo para identificar población en riesgo
- Programas de prevención y recomendaciones personalizadas
- Apps de salud con feedback automático
- Investigación en salud pública

Entregable

El trabajo debe presentarse como un **informe estructurado**, con:

- Texto explicativo
- Fórmulas cuando sea necesario
- Gráficos y tablas bien interpretados

No se evaluará solo el resultado, sino **la comprensión y el razonamiento** detrás de cada decisión.